
SKALA 4기 과제 제출 보고서 · 평가 보고서

KV cache 최적화 기술 다관점 평가 보고서

- 판교 9반 1조 -

SKALA

과정 | SKALA 4기 · AI

반 / 조 | 9반 1조

팀 원 | P284 김정인

팀 원 | P285 김지수

팀 원 | P286 김진수

팀 원 | P304 전진만

팀 원 | P307 정원준

제출일 2026. 09. 22.

목차

장	쪽	장	쪽
SUMMARY	2	4. 관점별 평가	4
1. 분석 배경	2	5. 시사점	7
2. 기술 선정	3	6. 한계점	8
3. 기술 개요	3	REFERENCE	9

SUMMARY

- TurboQuant: TRL 4-5(추정, 신뢰도 높음), 시장성 4.35, 이해관계자 5.00, 도메인 적합성 4.78 [1, p.15; 3]
- ITME: TRL 4-5(추정, 신뢰도 낮음), 시장성 판단 보류, 이해관계자 5.00, 도메인 적합성 판단 보류 [2, p.2-8]
- 가설 판정: H1 부분 지지, H2 부분 지지, H3 판단 보류, H4 지지 [2, p.2-8]
- TurboQuant은 NVIDIA A100 GPU에서 실험실 환경 부품 검증과 커뮤니티 구현을 통한 유사 환경 통합 검증 사례가 보고되어 TRL 4~5로 추정된다[1, p.15; 4; 3; 5].
- ITME는 FPGA 프로토타입과 실제 GPU 및 CXL 하이브리드 메모리 서버를 이용한 실험실 환경에서 구성요소 검증이 이루어져 TRL 4~5로 추정된다[2, p.2-8-10].
- 우열이나 추천이 아니라 관점별 평가 차이와 그 근거를 정리한 결과이다(판단 보류는 근거 부족을 뜻함).

1. 분석 배경

1.1 KV cache 병목

LLM은 토큰을 생성하면서 앞에서 계산한 Key-Value를 KV cache에 저장해 다시 쓰고, 그 크기는 문맥 길이와 동시 요청 수에 비례해 커진다. 두 기술의 원 논문도 이 메모리 병목을 출발점으로 삼는다 [1, p.1; 2, p.1]. Llama-3.1-8B(레이어 32, KV 헤드 8, 헤드 차원 128, FP16) 기준으로 토큰 하나에 128 KiB, 128K 토큰 요청 한 건에 16 GiB가 필요하다(조 계산, 설계서 A.1).

1.2 분석 질문과 가설

구분	내용
Q1	두 기술은 관점마다 어떤 근거로 어떻게 평가되는가
Q2	관점끼리 어디서 일치하고 어디서 엇갈리며, 그 이유는 무엇인가
Q3	워크로드(W1, W2)와 함께 쓰는 경우에 따라 평가 조건이 어떻게 달라지는가
H1	기술 성숙도와 시장의 평가는 같은 방향이 아닐 수 있다(TRL×시장 격자로 판정)
H2	이해관계자 반응은 기술 자체보다 속한 생태계의 영향을 더 받을 수 있다
H3	같은 도메인 안에서도 W1과 W2에 따라 적용 조건과 제약에 대한 평가가 달라질 수 있다
H4	두 방식은 경쟁보다 보완 관계일 수 있다

2. 기술 선정

2.1 선정 방식과 기준

가이드의 두 방식 중 조가 직접 고르는 2안을 택했다. Doc Pool 후보 6개를 비교 공정성 35%, 근거 확보성 25%, 산업 연관성 25%, 최신성 15%로 채점하고, KV cache를 직접 다루지 않거나 적용 시점이 크게 다른 후보는 제외했다(설계서 A.2). 에이전트는 선정을 바꾸지 않고 원문 근거로 검증만 한다.

2.2 선정 결과와 사유

- **TurboQuant** (Google, SW): 후보 6개 가중합 SW 최고점(4.35). 재학습 없이 서빙 단계에서 KV를 양자화한다 [1, p.1]
- **ITME** (SK hynix, HW): 후보 6개 가중합 HW 최고점(4.50). vLLM 위의 서빙 계층 기술로 모델을 바꾸지 않고 KV 공간을 CXL-hybrid 메모리로 넓힌다 [2, p.1]

3. 기술 개요

3.1 TurboQuant

- **작동 원리**: TurboQuant은 고차원 유클리드 벡터를 왜곡률을 최소화하며 양자화하는 벡터 양자화 문제를 다룬다. 입력 벡터를 무작위로 회전시켜 각 좌표가 베타 분포를 따르도록 유도하고, 고차원에서 좌표 간 독립성에 기반해 각 좌표별로 최적의 스칼라 양자화를 적용한다 [1, p.1-2].
- **실험 조건**: 실험은 1536차원 및 3072차원 OpenAI 임베딩, GloVe 임베딩 데이터셋을 사용하였으며, 100,000개 데이터 포인트를 훈련 및 평가에 활용했다 [1, p.19-20].
- **보고된 성능**: TurboQuant은 LongBench 데이터셋에서 Llama-3.1-8B-Instruct 및 Ministral-7B-Instruct 모델에 대해 기존 방법들보다 높은 평균 점수를 기록했다 [1, p.16-18-19].

- **한계:** TurboQuant은 PQ 대비 일부 설정에서 품질 저하가 관찰되었으며, RabbitQ는 GPU 가속이 불가능해 속도 면에서 불리하다. 또한, 논문에서는 비트 폭이 4 이상일 때 Panter-Dite 공식을 적용해 왜곡률을 추정하지만, 고비트 폭에서의 실제 성능과 효율성에 대한 상세한 분석은 부족하다 [1, p.11-20].

3.2 ITME

- **작동 원리:** ITME는 대규모 언어 모델(LLM) 추론에서 모델 가중치와 키-값(KV) 캐시 데이터를 다계층 메모리 구조를 통해 효율적으로 관리한다. GPU 메모리, 호스트 메모리, NVMe SSD, 클러스터 공유 저장소 등 다양한 메모리 계층을 활용하며, GPU 연산과 원격 CXL-하이브리드 메모리 간 데이터 이동을 비동기적으로 처리하여 GPU 활용도를 극대화한다 [2, p.1-2-4-6].
- **실험 조건:** ITME는 vLLM 프레임워크 위에 구현되었으며, Llama-3.1 8B 및 70B 모델을 대상으로 ShareGPT 데이터셋에서 128개의 동시 대화, 각 대화당 최소 2000 토큰, 최대 5턴 환경에서 평가되었다 [2, p.4-6-9-10].
- **보고된 성능:** ITME는 Llama-3.1 8B 및 70B 모델에서 GPU 메모리 기반 재계산 대비 토큰 생성 첫 시간(TTFT)에서 최대 약 2.5배의 속도 향상을 보였다 [2, p.9-10].
- **한계:** ITME는 NVMe SSD의 내부 아키텍처로 인해 대용량 비동기 쓰기 작업이 읽기 작업과 경쟁하여 I/O 병목 현상을 유발할 수 있다. 또한, 메타데이터 업데이트가 3단계 원자적 연산으로 처리되어 메타데이터 처리량이 제한될 수 있으며, FPGA 프로토타입은 CMM 기반 구현 대비 성능 저하가 관찰되었다 [2, p.4-6-10-11].

4. 관점별 평가

4.0 평가 기준

기준마다 1~5점 인식 점수(공개 자료에 나타난 평가의 방향, 기술 품질 아님)를 C.6 Rubric 근거 조건으로 매긴다. 기술 고유 근거만 세고 같은 원 출처 계열은 하나로 센다. 근거 1계열 이하 기준은 판단 보류, 빠진 가중치가 50%를 넘으면 관점 전체를 판단 보류로 한다.

4.1 기술 성숙도(TRL)

기술	TRL 범위(추정)	신뢰도	하한 근거	상한 근거
TurboQuant	4-5	높음	[1, p.15-16-19; 6; 4; 7; 8; 9]	[3; 10; 5]
ITME	4-5	낮음	[2, p.8-10]	[2, p.2]

TRL은 공개 정보로 추정된 범위이다. 하한은 공개 근거로 확인된 가장 높은 단계, 상한은 발표·계획 같은 부분 신호로 보이는 단계이며, 양쪽 모두 개발사 외 독립 근거가 있으면 신뢰도 높음, 한쪽만 있으면 보통, 개발사 자료뿐이면 낮음이다(설계서 C.4). TurboQuant은 NVIDIA A100 GPU에서 이론과 실험적 검증이 이루어지고 GitHub에 오픈소스 구현이 있어 실험실 환경 부품 검증 단계에 해당하며, 커뮤니티 구현을 통한 vLLM 통합과 4xH100 클러스터에서 실제 워크로드 검증 사례가 있어 유사 환경 통합 검증 단계 가능성이 보인다[1, p.15; 4; 3; 5]. 다만 공식 Google 구현은 2026년 2분기 이후 공개 예정으로 완전한 시제품 시연이나 고객사 적용 사례는 아직 공개되지 않았다. ITME는 FPGA 프로토타입과 실제 GPU 및 CXL 하이브리드 메모리 서버를 이용한 실험실 환경에서 기능 검증과 성능 가능성을 평가하였으며, LLM

추론에 적용하는 구체적 목표와 데이터 배치 전략이 논문에서 제시되어 유사 환경 통합 검증 가능성을 시사한다[2, p.2-8-10].

4.2 시장성

기준 (가중치)	TurboQuant	ITME
시장 규모·성장 (25)	4.00 [11; 12; 13]	판단 보류 [2, p.2]
상용화·채택 (30)	4.00 [14; 15; 16]	판단 보류 [2, p.9]
생태계 지원 (30)	5.00 [1, p.16-18]	판단 보류 [17]
도입 비용 구조 (15)	판단 보류 [16]	판단 보류
가중 평균	4.35	판단 보류

TurboQuant은 KV 캐시 메모리를 6배 이상 압축하고 정확도 손실 없이 속도 향상을 달성하여 AI 추론 비용 절감과 새로운 사용 사례 가능성을 제시하며, 오픈소스 구현과 기존 추론 스택 통합 가능성에 대한 논의가 활발하다[16; 12; 15; 5]. 다만 공식 제품 및 코드 발표가 부족하고 일부 모델에만 적용 가능하다는 제한점이 있다. ITME는 LLM 데이터 유형에 따른 계층적 메모리 관리와 PCIe Gen5 인터페이스를 활용한 고대역폭 KV 캐시 교체, CXL 하이브리드 메모리 기반 다중 터 추론 성능 개선을 시연하여 시장 수요와 성장 가능성을 시사한다[2, p.2; 17].

4.3 이해관계자

집단 (각 25)	TurboQuant	ITME
(a) 클라우드·데이터센터	지지(5) [18; 19; 16]	지지(5) [20; 21; 22]
(b) GPU·메모리 벤더	판단 보류	지지(5) [23; 24; 25]
(c) 개발자	지지(5) [26; 27; 28]	지지(5) [29; 30; 31]
(d) 투자·분석·언론	지지(5) [32; 33; 34]	지지(5) [35; 36; 37]
가중 평균	5.00	5.00

개발사(TurboQuant는 Google, ITME는 SK hynix)의 발언과 보도자료는 점수에서 제외하고 참고로만 인용했다. TurboQuant은 클라우드·데이터센터 사업자, 개발자 커뮤니티, 투자·분석·언론 집단에서 KV 캐시 압축과 속도 향상, 정확도 유지 측면에서 긍정적 평가가 다수 존재하며 우려 근거는 발견되지 않았다[18; 26; 32]. 다만 GPU·메모리 벤더 집단에 대한 근거는 없어 평가가 제한적이다. ITME는 클라우드 사업자와 투자자 그룹에서 기술과 시장성에 대한 신뢰가 높고, GPU·메모리 벤더 및 개발자 커뮤니티에서도 긍정적 평가가 우세하나 일부 우려 근거도 존재한다[20; 35; 38].

4.4 도메인 적합성(W1·W2)

항목 (각 20)	TurboQuant W1	TurboQuant W2	ITME W1	ITME W2
비용	5.00 [6; 39]	5.00 [40; 41]	판단 보류 [2, p.2]	판단 보류 [2, p.2]
지연	5.00 [6; 42]	4.00 [40; 41]	판단 보류 [2, p.2]	판단 보류 [2, p.2]
처리량·동시성	5.00 [39; 28]	4.00 [40; 41]	판단 보류 [17]	판단 보류 [17]
정확도 영향	5.00 [1, p.18; 42]	5.00 [1, p.18; 43]	판단 보류	판단 보류
통합 난이도	5.00 [44; 45]	판단 보류 [9]	판단 보류	판단 보류
가중 평균	4.78		판단 보류	

워크로드별 평균: TurboQuant W1 5.00, W2 4.50; ITME W1 판단 보류, W2 판단 보류. 가중 평균 행은 기술별 W1·W2 합산값이다(W1 열에 표기). TurboQuant은 KV 캐시를 3비트 수준으로 압축하여 5~6배 메모리 절감과 최대 8배 어텐션 속도 향상을 달성하며, 다양한 LLM과 데이터셋에서 정확도 손실 없이 적용되었다[6; 1, p.18; 42; 46]. Triton 커널로 구현되어 vLLM과 통합되었고 RTX 3090 및 5090 GPU에서 검증되었다[9]. 다만 BF16 및 FP8 대비 처리량과 지연에서 일부 부정적 평가가 존재하며, 대규모 실서비스 적용 사례는 부족하다[40; 47].

4.5 추가 관점(Orchestrator 동적 계획, 점수 없음)

- T05 regulation and compliance · TurboQuant: TurboQuant는 기술 관련 규제, 표준, 컴플라이언스 요구사항에 대한 직접적인 언급은 없으나, KV 캐시 메모리 압축을 통해 GPU 메모리 사용량을 크게 줄여 장기 컨텍스트 처리 및 멀티세션 운영에서 효율성을 높임으로써 규제 환경에서 요구되는 대규모 데이터 처리와 컴플라이언스 준수에 기여할 가능성이 있다 [15; 48].
- T05 regulation and compliance · ITME: SK hynix는 반도체 공급망에서 공정 거래 관행을 확립하기 위해 모든 관련 법률과 규정을 자발적으로 준수하며, 반도체 산업 특성에 맞는 규제도 포함하여 다양한 관할권의 법률과 국제 프로토콜을 이해하고 있다 [49].
- T06 competition and ecosystem · TurboQuant: TurboQuant은 KV 캐시 메모리 압축을 통해 GPU 메모리 사용량을 크게 줄여 LLM이 더 긴 대화와 더 큰 모델을 기존 인프라에서 지원할 수 있도록 한다[16; 27].
- T06 competition and ecosystem · ITME: SK hynix는 AI 메모리 시장에서 NAND를 단순 저장장치가 아닌 핵심 구성요소로 보고 고용량·고성능 NAND 제품을 확대하며, 고객 및 생태계 파트너와의 개방형 협력을 통해 AI 인프라 전반의 혁신을 가속화하고 있다 [50; 51].

5. 시사점

5.1 관점 간 일치·상충 표

기술	TRL(범위)	시장성	이해관계자	도메인
TurboQuant	4-5	4.35	5.00	4.78
ITME	4-5	판단 보류	5.00	판단 보류

기술	관점 쌍	점수 차	판정
TurboQuant	시장성 - 이해관계자	0.65	일치
TurboQuant	시장성 - 도메인 적합성	0.43	일치
TurboQuant	이해관계자 - 도메인 적합성	0.22	일치

판정 기준: 점수 차 2.0 이상 상충, 1.0 이상 2.0 미만 부분 상충, 1.0 미만 일치. 같은 기술 안에서만 비교하고 두 기술을 합치거나 순위를 매기지 않는다.

5.2 주요 상충 지점

- 상충 또는 부분 상충으로 판정된 관점 쌍이 없거나, 해설 문장이 Judge 근거 검사를 통과하지 못해 표의 판정만 실는다.

5.3 가설 판정

가설	판정	근거
H1	부분 지지	TurboQuant: TRL 4-5 (신뢰도 높음), 시장성 4.35 → 부분 괴리 (기대 선행); ITME: TRL 4-5 (신뢰도 낮음), 시장성 판단 보류 → 판단 보류 (C.5 격자, 코드 계산) [2, p.2-8-10; 1, p.15]
H2	부분 지지	TurboQuant: 기술 언급 12건, 생태계 전략 언급 5건 → 기각; ITME: 기술 언급 15건, 생태계 전략 언급 20건 → 지지 (개발사 발언 제외, C.7 기준, 코드 계산) [20; 18; 23; 35]
H3	판단 보류	TurboQuant: W1 5.0, W2 4.5, 3점을 사이에 두고 갈리는 기준 없음 → 기각; ITME: W1-W2 점수를 낼 근거가 부족해 판단 보류 (평가 가능한 기술이 일부분이라 가설 전체는 판단 보류) (C.7 기준, 코드 계산) [2, p.2; 6; 39]
H4	지지	근거 문장이 Judge 검사를 통과하지 못함 [26; 9; 52]

H1은 TRL 범위의 가운데 값과 시장성 점수로 설계서 C.5의 3×3 격자에서 코드로 판정했다: TurboQuant 부분 괴리 (기대 선행); ITME 판단 보류.

5.4 조건별 시사점(추천 아님)

- 대규모 LLM 추론 워크로드에서 KV 캐시 메모리 압축과 속도 향상이 중요할 경우 TurboQuant의 6배 압축 및 8배 속도 향상 근거가 관련된다[16; 12; 53].

- 기존 GPU 보유 여부가 높은 환경에서는 TurboQuant의 GPU 기반 오픈소스 구현과 vLLM 통합 사례가 적용 가능성을 시사한다[4; 3; 5].
- 대규모 KV 캐시 풋프린트와 다중 턴 추론이 요구되는 환경에서는 ITME의 다계층 메모리 구조와 CXL 하이브리드 메모리 활용 근거가 관련된다[2, p.9; 17].
- 클라우드 및 데이터센터 사업자 도입 주체에서는 TurboQuant과 ITME 모두 긍정적 평가 근거가 존재하나, GPU-메모리 벤더 집단 근거는 TurboQuant에 부족하고 ITME는 일부 존재한다[18; 20; 23].

6. 한계점

6.1 확증편향 방지 조치와 실행 결과

관점	Judge 근거·종합·다양성·완결	최대 계열 비중	찬반·범위 근거 계열	우열 어휘	재실행	결과
TRL	5/5/4/4	38%	TurboQuant 하·상한 3, ITME 하·상한 1	0	1	통과
시장성	5/5/4/4	100%	TurboQuant 찬8/반2, ITME 찬2/반0	0	1	판정 불확실
이해관계자	4/4/4/4	14%	TurboQuant 찬15/반0, ITME 찬21/반7	0	1	판정 불확실
도메인 적합성	5/5/4/4	100%	TurboQuant 찬22/반1, ITME 찬2/반0	0	1	판정 불확실

- 본문 인용 근거의 출처 구분: 벤더 27건, 제3자 42건, 학술 3건. 관점마다 지지·반대 질의를 짝지어 검색했고, 한 원 출처 계열이 웹 근거의 50%를 넘지 않게 했으며, 개발사 발언은 이해관계자 점수에서 뺐다.
- Orchestrator가 SubTask 6개를 동적으로 계획했다(계획 출처 llm, 사용 Agent 6개, 미사용 Agent 1개).
- Judge 판정식은 설계서 D.5를 그대로 썼다. 기준에 못 미친 작업만 같은 담당 Agent가 1회 다시 실행했고, 미사용 Agent의 교차 검토와 Agent 0의 재시도 지시를 거쳤다. 재시도 후에도 미달이면 판정 불확실로 남겼다.
- 재시도 후 미달·부분 결과 작업: T02(FAILED_AFTER_RETRY), T03(FAILED_AFTER_RETRY), T04(FAILED_AFTER_RETRY)
- 판정 불확실: 작업 T02(marketability, market_specialist)이 재시도 1회 후에도 기준 미달 → FAILED_AFTER_RETRY. 사유: 한 출처 계열 비중 100%(50% 초과) / itme: 찬성 2계열·반대 0계열(각 2 이상 필요) / ITME의 한계와 비용 구조에 대한 근거가 부족하며, 모든 평가 항목에서 독립적인 제3자 출처가 더 보장되어야
- 판정 불확실: 작업 T03(stakeholder perspective, stakeholder_specialist)이 재시도 1회 후에도 기준 미달 → FAILED_AFTER_RETRY. 사유: turboquant: 찬성 15계열·반대 0계열(각 2 이상 필요)
- 판정 불확실: 작업 T04(domain applicability, domain_specialist)이 재시도 1회 후에도 기준 미달 → FAILED_AFTER_RETRY. 사유: 한 출처 계열 비중 100%(50% 초과) / turboquant: 찬성 22계열·반대 1계열(각 2 이상 필요) / itme: 찬성 2계열·반대 0계열(각 2 이상 필요) / ITME의 경우 정확도(accuracy)

REFERENCE

논문

- [1] Zandieh, A., Daliri, M., Hadian, M., & Mirrokni, V.(2025). TurboQuant: Online Vector Quantization with Near-optimal Distortion Rate. arXiv, 2504.19874.
- [2] Jang, H., Min, Y., Kim, S., Ahn, T., Kim, H., Joo, Y., Kim, H., & Kim, J.(2026). ITME: Inference Tiered Memory Expansion with Disaggregated CXL-Hybrid Memories. arXiv, 2606.12556.

웹페이지

- [3] medium.com(2026-09-22 접속). Medium. <https://medium.com/@anupkawarase.akz/turboquant-how-googles-6x-kv-cache-compression-changes-llm-inference-forever-1110e4be289e>
- [4] github.com(2026-09-22 접속). OmarHory/turboquant: Open-source implementation . <https://github.com/OmarHory/turboquant>
- [5] dev.to(2026-09-22 접속). TurboQuant: What Developers Need to Know About . <https://dev.to/arshtechpro/turboquant-what-developers-need-to-know-about-googles-kv-cache-compression-eeg>
- [6] turboquant.net(2026-09-22 접속). TurboQuant.net - Independent TurboQuant Analysis. <https://turboquant.net>
- [7] GitHub(2026-09-22 접속). GitHub - hackimov/turboquant-kv: Open-source PyTorch implementation of Google.... <https://github.com/hackimov/turboquant-kv>
- [8] DEV Community(2026-09-22 접속). TurboQuant: What Developers Need to Know About Google's KV Cache Compression. <https://translate.google.com/translate?u=https%3A%2F%2Fdev.to%2Farshtechpro%2Fturboquant-what-developers-need-to-know-about-googles-kv-cache-compression-eeg&hl=pt&sl=en&tl=pt&client=srp>
- [9] GitHub(2026-09-22 접속). GitHub - 0xSero/turboquant: TurboQuant: Near-optimal KV cache quantization for.... <https://github.com/0xSero/turboquant>
- [10] deepinfra.com(2026-09-22 접속). What Is Google TurboQuant and What Does It Mean . <https://deepinfra.com/blog/google-turboquant>
- [11] tradingkey.com(2026-09-22 접속). What Is Google TurboQuant Compression Algorithm? How Does It Affect the AI.... <https://tradingkey.com/analysis/stocks/us-stocks/261728257-what-is-google-turboquant-compression-algorithm-how-impact-ai-memory-chip-industry-tradingkey>
- [12] CryptoRank.io(2026-09-22 접속). Google TurboQuant: Revolutionary AI Memory Compression Sparks 'Pied Piper'.... <https://cryptorank.io/ru/news/feed/ee99c-google-turboquant-ai-memory-compression>
- [13] reddit.com(2026-09-22 접속). Will Google's TurboQuant technology save us? : r/StableDiffusion. https://www.reddit.com/r/StableDiffusion/comments/1s6t8yu/will_googles_turboquant_technology_save_us
- [14] github.com(2026-09-22 접속). Add TurboQuant KV Cache Quantization for Memory-Efficient Long . <https://github.com/sgl-project/sglang/issues/21618>
- [15] Medium(2026-09-22 접속). TurboQuant Changes the Economics of Local AI Inference. <https://medium.com/@michael.hannecke/googles-turboquant-changes-the-economics-of-local-ai-inference-acce5839014d>
- [16] starkinsider.com(2026-03). Google's TurboQuant: The Unsexy AI Breakthrough Worth Watching. <https://www.starkinsider.com/2026/03/google-turboquant-llm-compression-less-memory.html>
- [17] arxiv.org(2026-09-22 접속). ITME: Inference Tiered Memory Expansion with . <https://arxiv.org/html/2606.12556v2>
- [18] instagram.com(2026-09-22 접속). Turboquant Google Kv Cache Compression Paper Iclr 2026. <https://www.instagram.com/popular/turboquant-google-kv-cache-compression-paper-iclr-2026>
- [19] BSWEN(2026-03-27). What is Google TurboQuant? KV Cache Compression Explained. <https://docs.bswen.com/blog/2026-03-27-what-is-google-turboquant-kv-cache-compression>
- [20] futurumgroup.com(2026-09-22 접속). SK Hynix ADR Issuance Strategy. <https://futurumgroup.com/insights/will-sk-hynix-record-265bn-adr-issuance-help-close-its-capex-intensity-gap>
- [21] arxiv.org(2026-09-22 접속). ITME: Inference Tiered Memory Expansion with Disaggregated CXL-Hybrid Memories. <https://arxiv.org/html/2606.12556>
- [22] The Neural Feed(2026-09-22 접속). SK Hynix's ITME uses CXL memory to boost LLM inference by. <https://theneuralfeed.com/article/itme-inference-tiered-memory-expansion-with-disaggregated-cxl-hybrid-memories/HxcbGQ4G>
- [23] Global Equity Briefing(2026-09-22 접속). SK Hynix Deep Dive: 4x P/E is Too Cheap!. <https://www.globalequitybriefing.com/p/sk-hynix-deep-dive-4x-pe-is-too-cheap>
- [24] semidynamics.com(2026-09-22 접속). Semidynamics Secures a Strategic Investment to Advance Memory-Centric AI.... <https://semidynamics.com/newsroom/press-releases/post/semidynamics-secures-a-strategic-investment-to-advance-memory-centric-ai-inference-chips>
- [25] blocksandfiles.com(2026-02-16). SK Hynix proposes HBM and HBF hybrid for LLM inference. <https://www.blocksandfiles.com/flash/2026/02/16/sk-hynix-proposes-hbm-and-hbf-hybrid-for-llm-inference/4091326>
- [26] NVIDIA Developer Forums(2026-09-22 접속). Why Turboquant saves DGX twice. <https://forums.developer.nvidia.com/t/why-turboquant-saves-dgx-twice/364736>
- [27] towardsdatascience.com(2026-09-22 접속). KV Cache Is Eating Your VRAM. Here's How Google Fixed . <https://towardsdatascience.com/kv-cache-is-eating-your-vram-heres-how-google-fixed-it-with-turboquant>

- [28] reddit.com(2026-09-22 접속). [google research] TurboQuant: Redefining AI efficiency .
https://www.reddit.com/r/LocalLLaMA/comments/1s2su28/google_research_turboquant_redefining_ai
- [29] lmcache.ai(2026-04-28). Stop Calling It KV Cache: It's Something Much Bigger. https://blog.lmcache.ai/en/2026/04/28/stop-calling-it-kv-cache-its-something-much-bigger
- [30] weka.io(2026-09-22 접속). Inference Is Eating Memory, and Tokens Now Run AI Economics. https://www.weka.io/video/inference-is-eating-memory-and-tokens-now-run-ai-economics
- [31] WEKA(2026-09-22 접속). AI storage that fixes KV cache bottlenecks. https://www.weka.io/article/the-real-state-of-ai-hype-vs-reality
- [32] decodingdiscontinuity.com(2026-09-22 접속). Why TurboQuant Triggered a \$100B Memory Stock Sell-Off. https://www.decodingdiscontinuity.com/p/turboquant-memory-stock-sell-off-panic-paper-google
- [33] yahoo.com(2026-09-22 접속). What TurboQuant Actually Means for AI Memory Stocks. https://finance.yahoo.com/markets/stocks/articles/turboquant-actually-means-ai-memory-125500558.html
- [34] mindstudio.ai(2026-09-22 접속). What Is Google TurboQuant? The KV Cache Compression . https://www.mindstudio.ai/blog/what-is-google-turboquant-kv-cache-compression
- [35] fitchratings.com(2026-09-22 접속). Fitch Upgrades SK hynix to 'BBB+'; Outlook Stable. https://www.fitchratings.com/research/corporate-finance/fitch-upgrades-sk-hynix-to-bbb-outlook-stable-30-04-2026
- [36] cnbc.com(2026-01-28). SK Hynix doubles profit in 2025 amid memory shortage. https://www.cnbc.com/amp/2026/01/28/sk-hynix-smashes-earnings-estimates-as-ai-memory-demand-drives-record-profit.html
- [37] substack.com(2026-09-22 접속). The memory sector has plummeted ,what is the market panicking . https://globalsemiresearch.substack.com/p/the-memory-sector-has-plummeted-what
- [38] yahoo.com(2026-09-22 접속). Analysts Still See Massive Upside for SK Hynix – The AI Cycle Isn't Done But.... https://finance.yahoo.com/markets/stocks/articles/analysts-still-see-massive-upside-151554133.html
- [39] spheron.network(2026-09-22 접속). Google TurboQuant: 6x KV Cache Compression for LLM Inference. https://www.spheron.network/blog/google-turboquant-llm-compression-gpu-cloud
- [40] vllm(2026-05-11). A First Comprehensive Study of TurboQuant: Accuracy and . https://vllm.ai/blog/2026-05-11-turboquant
- [41] o-mega.ai(2026-09-22 접속). Google TurboQuant in August 2026: Where It Actually Runs. https://o-mega.ai/articles/google-turboquant-the-2026-llm-compression-guide
- [42] Google(2026-09-22 접속). TurboQuant: Redefining AI efficiency with extreme . https://research.google/blog/turboquant-redefining-ai-efficiency-with-extreme-compression
- [43] towardsai.net(2026-09-22 접속). Google's TurboQuant Explained: How They Cut LLM . https://pub.towardsai.net/googles-turboquant-how-they-cut-llm-memory-by-6x-without-losing-accuracy-971313c9aa7e
- [44] Intel(2026-09-22 접속). Enhancing long-context, high-concurrency LLM serving on a 32 GB . https://community.intel.com/t5/Blogs/Tech-Innovation/Data-Center/Enhancing-long-context-high-concurrency-LLM-serving-on-a-32-GB/post/1751209
- [45] tether.io(2026-09-22 접속). TurboQuant in QVAC SDK 0.12.0: KV-cache quantization for pr.... https://qvac.tether.io/blog/turboquant-in-qvac-sdk-0-12-0-kv-cache-quantization-for-production-local-ai
- [46] jangwook.net(2026-09-22 접속). Google TurboQuant: 3-Bit KV Cache With Zero Accuracy Loss. https://jangwook.net/en/blog/en/google-turboquant-kv-cache-3bit-compression
- [47] CryptoRank.io(2026-09-22 접속). Google TurboQuant: Revolutionary AI Memory Compression Sparks 'Pied Piper'.... https://cryptorank.io/news/feed/ee99c-google-turboquant-ai-memory-compression
- [48] TurboQuant(2026-09-22 접속). TurboQuant, KV Cache, 그리고 LLM 메모리 최적화. https://donghwanjeong.github.io/turboquant
- [49] SK hynix(2026-09-22 접속). Compliance < Business Principles< ESG < Sustainability < . https://www.skhynix.com/sustainability/UI-FR-SA11
- [50] x.com(2026-09-22 접속). Jukan 🦋 OCP 2026 on X: "SK hynix conference call – NAND-related comments Q. How.... https://x.com/jukan05/status/2047117081230057881
- [51] SK hynix Newsroom(2026-09-22 접속). SK hynix's technology roadmap for co-packaged optics features in 'Nature.... https://news.skhynix.com/en/cpo-in-nature-electronics
- [52] arxiv.org(2026-09-22 접속). A KV Cache Framework for Multi-Turn LLM Serving with CXL-Hybrid . https://arxiv.org/html/2607.18141v1
- [53] regolo.ai(2026-09-22 접속). Why TurboQuant matters for real-world LLM inference. https://regolo.ai/why-turboquant-matters-for-real-world-llm-inference